




**UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
UNIDADE ACADÊMICA ESPECIALIZADA EM CIÊNCIAS AGRÁRIAS –
ESCOLA AGRÍCOLA DE JUNDIAÍ
CURSO SUPERIOR DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE
SISTEMAS**

Gustavo Gonçalves Maciel

**SEGMENTAÇÃO AUTOMÁTICA DE OBJETOS EM IMAGENS RESULTANTES DE
EXPERIMENTOS DE MEMÓRIA UTILIZANDO TÉCNICAS DE PROCESSAMENTO
DIGITAL DE IMAGENS**

Macaíba, RN

2023



Gustavo Gonçalves Maciel

SEGMENTAÇÃO AUTOMÁTICA DE OBJETOS EM IMAGENS RESULTANTES DE
EXPERIMENTOS DE MEMÓRIA UTILIZANDO TÉCNICAS DE PROCESSAMENTO
DIGITAL DE IMAGENS

Monografia apresentada ao curso superior de Tecnologia em Análise e Desenvolvimento de Sistemas, da Universidade Federal do Rio Grande do Norte, como requisito parcial à obtenção do título de Tecnólogo em Análise e Desenvolvimento de Sistemas.

Orientador(a): Profa. Dra. Alessandra Mendes Pacheco.

Coorientador(a): Profa. Dra. Maria Carolina Gonzalez.

Macaíba, RN

2023

Maciel, Gustavo Gonçalves.

Segmentação automática de objetos em imagens resultantes de experimentos de memória utilizando técnicas de processamento digital de imagens / Gustavo Gonçalves Maciel. - 2023.

55f.: il.

Monografia (graduação) - Universidade Federal do Rio Grande do Norte, Unidade Acadêmica Especializada em Ciências Agrárias, curso superior de Tecnologia em Análise e Desenvolvimento de Sistemas. Macaíba, RN, 2023.

Orientadora: Profa. Dra. Alessandra Mendes Pacheco.

Coorientadora: Profa. Dra. Maria Carolina Gonzalez.

1. Processamento digital de imagens - Monografia. 2. Reconhecimento de objetos - Monografia. 3. Segmentação de objetos - Monografia. 4. Memória - Monografia. 5. Coordenadas - Monografia. I. Pacheco, Alessandra Mendes. II. Gonzalez, Maria Carolina. III. Título.

RN/UF/BSPRH

CDU 621.397.331

Gustavo Gonçalves Maciel

**SEGMENTAÇÃO AUTOMÁTICA DE OBJETOS EM IMAGENS RESULTANTES DE
EXPERIMENTOS DE MEMÓRIA UTILIZANDO TÉCNICAS DE PROCESSAMENTO
DIGITAL DE IMAGENS**

Trabalho de conclusão de curso de graduação apresentado à Unidade Acadêmica Especializada em Ciências Agrárias – Escola Agrícola de Jundiá da Universidade Federal do Rio Grande do Norte como requisito parcial para a obtenção do título de Tecnólogo em Análise e Desenvolvimento de Sistemas.

Aprovado em: _____ de _____ de 20____.

BANCA EXAMINADORA

Profa. Dra. Alessandra Mendes Pacheco - UFRN (Orientadora)

Profa. Dra. Maria Carolina Gonzalez - ISD (Coorientadora)

Profa. Dra. Tásia Moura Cardoso do Vale - UFRN

Prof. Dr. Leonardo Rodrigues de Lima Teixeira - UFRN

Dedico este trabalho ao meu Deus, à
minha mãe e aos que moldaram
minha jornada. Aos mestres, amigos e
oportunidades.

AGRADECIMENTOS

Gostaria de expressar meus sinceros agradecimentos em primeiro lugar a Deus, cuja presença e orientação foram fundamentais ao longo de toda a minha vida. Em segundo lugar, à minha mãe, Arioneide Gonçalves Pereira Maciel, cujo trabalho incansável e incentivo constante me impulsionaram a alcançar este marco em minha vida acadêmica, sem vocês eu não seria nada.

Aos meus estimados professores, minha admiração e gratidão por terem sido verdadeiras fontes de inspiração. Em particular, gostaria de expressar minha sincera gratidão às minhas orientadoras nesse trabalho, professora Alessandra Mendes Pacheco e professora Maria Carolina Gonzalez. Seus valiosos ensinamentos, orientações e apoio foram fundamentais para despertar e fortalecer meu interesse pela pesquisa. Sem vocês, essa jornada não teria sido a mesma, e é com profundo agradecimento que carrego tudo que aprendi.

Não posso deixar de mencionar meus queridos amigos Luan Magioli, Anderson Henrique, Ana Júlia e Roselene. Suas palavras de estímulo, apoio e perspectivas amplas me motivaram a superar desafios e acreditar em meu potencial. Cada um de vocês desempenhou um papel crucial nesta conquista, e sou grato por tê-los em minha vida.

Enfim, a todos que direta ou indiretamente contribuíram para a realização deste trabalho de conclusão de curso, meu profundo agradecimento. Esta conquista é compartilhada com todos vocês, e sou imensamente grato por fazerem parte dessa jornada que ficará eternamente marcada em minha trajetória acadêmica e pessoal.

"As pessoas ficam perturbadas, não pelas coisas, mas pela imagem que formam delas".

Epicteto

RESUMO

A tarefa de reconhecimento de objetos utiliza modelos animais com base na sua curiosidade natural por explorar itens novos, o que a torna uma ferramenta amplamente empregada na pesquisa para investigar diferentes fases da memória por meio do comportamento. Esse paradigma abrange desde a aquisição até a evocação e reconsolidação, fornecendo uma estrutura versátil para explorar múltiplos aspectos da memória. No entanto, a análise manual dos resultados pode ser demorada e suscetível a vieses potenciais. Nesse contexto, este trabalho tem o objetivo de desenvolver um sistema que automatize a identificação das coordenadas dos objetos presentes nas tarefas de reconhecimento com modelos animais, mais especificamente, com roedores. Essa informação é essencial para a aplicação de softwares que monitoram a quantidade e o tempo de exploração de cada item pelo animal, permitindo uma análise mais ágil e objetiva dos testes. Com isso, os pesquisadores poderão direcionar seu foco para outras etapas cruciais da investigação. Os resultados obtidos após a aplicação de técnicas de processamento de imagem demonstraram uma precisão de 99,01% na identificação dos itens, evidenciando uma diferença média de apenas 4,07 pixels em comparação com a marcação manual do centro do objeto.

Palavras-chave: Memória. Reconhecimento de Objetos. Segmentação de Objetos. Processamento Digital de Imagens. Coordenadas.

ABSTRACT

The object recognition task uses models based on their natural curiosity to explore new items, which makes it a widely used tool in research to investigate different stages of memory through behavior. This paradigm ranges from acquisition to recall and reconsolidation, providing a diverse framework for exploring multiple aspects of memory. However, manual analysis of results can be time consuming and susceptible to potential bias. In this context, this work aims to develop a system that automates the identification of coordinates of objects present in recognition tasks with animal models, more specifically, with rodents. This information is essential for the application of software that monitors the voice and the exploration time of each item by the animal, allowing a more agile and objective analysis of the tests. With this, investigators will be able to direct their focus to other crucial stages of the investigation. The results obtained after applying image processing techniques provided an accuracy of 99.01% in identifying items, showing an average difference of only 4.07 pixels compared to manual marking of the center of the object.

Keywords: Memory. Object Recognition. Object Segmentation. Digital Image Processing. Coordinates.

LISTA DE FIGURAS

FIGURA 1 – SEQUÊNCIA DE PROCESSAMENTO	22
FIGURA 2 – ITENS DO EXPERIMENTO	27
FIGURA 3 – ARENA DO EXPERIMENTO	28
FIGURA 4 – PIPELINE DO ALGORITMO	31
FIGURA 5 – COMPONENTES DOS EXPERIMENTOS	32
FIGURA 6 – IMAGEM SEM O ANIMAL	33
FIGURA 7 – TONS DE CINZA E APLICAÇÕES DE FILTROS	34
FIGURA 8 – CONTRASTES E CONTORNOS	35
FIGURA 9 – FUTURAS INTERPRETAÇÕES	37
FIGURA 10 – FLUXOGRAMA DA MANIPULAÇÃO DOS DADOS	38
FIGURA 11 – CÁLCULO DE PRECISÃO	39
FIGURA 12 – CÁLCULO DE RECALL OU TAXA DE DETECÇÃO	39
FIGURA 13 – CÁLCULO DE F1-SCORE	39
FIGURA 14 – CÁLCULO DA DISTÂNCIA EUCLIDIANA	40
FIGURA 15 – GRÁFICO BOXPLOT MANUAL X ALGORITMO	42

LISTA DE TABELAS

TABELA 1 – ATRIBUTO DOS OBJETOS	36
TABELA 2 – PARÂMETROS INICIAIS REFERENTES À DISTÂNCIA	43
TABELA 3 – PARÂMETROS FINAIS REFERENTES À DISTÂNCIA	44

SUMÁRIO

1. INTRODUÇÃO.....	14
1.1 Objetivo Geral.....	17
1.2 Objetivos Específicos.....	17
2. REFERENCIAL TEÓRICO.....	18
2.1. Conceitos Fundamentais.....	18
2.1.1. Estudos Comportamentais.....	18
2.1.2. Memória de Objetos e Experimentos.....	19
2.1.3. Tarefa para Reconhecimento de Novos Objetos (NOR).....	20
2.1.4. Processamento Digital de Imagem.....	21
2.2. Trabalhos Relacionados.....	24
2.2.1. Métodos de Aprendizagem de Máquina Aplicados a Análise de Imagens.....	24
2.2.2. Uso de Redes Neurais na Segmentação de Objeto.....	25
3. METODOLOGIA.....	27
3.1. Ferramentas - Tarefa de Reconhecimento de Novos Objetos:.....	27
3.1.1. Objetos.....	27
3.1.2. Ambientação.....	27
3.1.3. Câmeras.....	28
3.2. Ferramentas - Software.....	29
3.3. Sistema.....	30
3.3.1. Etapa: Pré-Aquisição das Imagens.....	31
3.3.2. Etapa: Aquisição das Imagens.....	33
3.3.3. Etapa: Pré-Processamento.....	33
3.3.4. Etapa: Segmentação.....	34
3.3.5. Etapa: Representação e Descrição.....	35
3.3.6. Etapa: Reconhecimento e Interpretação dos Dados.....	36
3.3.7. Etapa: Validação dos Resultados.....	37
4. RESULTADOS E DISCUSSÃO.....	41
4.1. Discussão dos Resultados.....	41
4.2. Precisão das Coordenadas.....	42
5. CONCLUSÃO.....	45
5.1. Contribuições.....	46
5.2. Trabalhos Futuros.....	47

REFERÊNCIAS.....	48
APÊNDICE A - BASE DE IMAGENS E RESULTADOS.....	50

1. INTRODUÇÃO

A memória de reconhecimento de objetos (ORM, do inglês Object recognition memory) é indispensável quando se trata da capacidade dos animais de distinguir entre novos elementos e elementos já conhecidos (Gonzalez et al., 2019). Nos experimentos atuais que investigam essa forma de memória, as câmeras digitais estão sendo utilizadas para adquirir dados e monitorar as ações dos modelos animais, facilitando o estudo e a observação dos experimentos. No entanto, surge a necessidade de sistemas automatizados que possam agilizar esse processo, fornecendo informações precisas e úteis para os pesquisadores (Egnor e Branson, 2016; Laurindo, 2022). Diante desse contexto, este trabalho se propõe a desenvolver um sistema que atenda a essa demanda, proporcionando uma análise eficiente e confiável dos dados coletados.

Inicialmente, as memórias são estabilizadas por um processo dependente de plasticidade sináptica conhecido como consolidação (Bear et al., 2017, p. 829; Kandel et al., 2014, p. 1261). Quando evocadas, as memórias consolidadas podem ser desestabilizadas, necessitando de um novo processo de re-estabilização ou reconsolidação (Rossato et al., 2019).

A reconsolidação é geralmente desencadeada pela evocação da memória em presença de novidade ou detecção de erros de predição, sugerindo que uma de suas principais funções é atualizar as memórias. Nessa fase, uma memória existente pode ser associada com as novas sensações com as quais o sujeito é exposto, gerando uma atualização dessas memórias e fortalecendo as sinapses em questão, conexões entre neurônios, e

enfraquecendo outras durante o processo que forma essa nova informação (BEAR et al., 2017).

As bases neurobiológicas da formação, expressão e atualização da memória de reconhecimento podem ser estudadas em roedores utilizando a tarefa de reconhecimento espontâneo de objetos, que se baseia na preferência inata desses animais pela novidade (Ennaceur e Delacour, 1988). Compreender como esses animais se comportam e tomam decisões pode fornecer informações sobre como o cérebro entende o mundo e organiza o conhecimento adquirido (Bunsey e Eichenbaum, 1996).

O interesse dessa metodologia de pesquisa com animais reside na possibilidade de colher características comportamentais sem a necessidade de procedimentos invasivos como lesões cerebrais ou estimulações cerebrais profundas por meio de eletrodos. Alguns métodos se baseiam na coleta de vídeos e áudios para extrair esses dados. No entanto, formular teses dessa forma sem o uso de ferramentas computacionais exigiria o uso de um recurso ainda mais valioso: o tempo. Realizar a identificação de exploração por parte do animal no objeto mediante observações do pesquisador pode custar horas ou até dias, ocupando o tempo desse profissional e, sendo uma tarefa que exigiria uma atenção constante e julgamento pessoal, possibilitando erros e diferenças entre os resultados obtidos de pesquisador para pesquisador.

A busca por abordagens mais econômicas é uma necessidade crucial. Dentre elas, técnicas que envolvem aprendizagem de máquina supervisionada e não supervisionada, redes neurais artificiais e processamento digital de imagem têm se destacado como promissoras em aplicações similares (Vale, 2014; Gandhi et al., 2018). Além de produzirem resultados comparáveis, essas metodologias apresentam vantagens

notáveis, como a habilidade de seguir padrões definidos e validados no contexto do sistema, minimizando erros decorrentes de julgamento humano e assegurando a conformidade com os procedimentos exigidos em pesquisas científicas.

Nesse sentido, este projeto pretende explorar a viabilidade de uma abordagem acessível e eficiente para automatizar a identificação de coordenadas de objetos em experimentos de reconhecimento de objetos. Utilizando técnicas avançadas de processamento digital de imagens, busca-se alcançar resultados comparáveis aos obtidos por algoritmos mais complexos, mas com a vantagem de requerer menos recursos, como extensos bancos de treinamento e longas horas de processamento e testes. Além disso, pretende-se destacar a relevância desse sistema automatizado como uma ferramenta valiosa para a análise e interpretação de dados comportamentais, tornando-se um passo importante na direção de otimizar a investigação em estudos de memória e outros campos da pesquisa científica.

1.1 Objetivo Geral

Desenvolver um algoritmo automatizado para extrair informações sobre os objetos presentes em vídeos de estudos de reconhecimento de objetos em experimentos com roedores em ambiente laboratorial. O foco principal será na coleta das coordenadas dos itens utilizados, desconsiderando a possível presença de animais no contexto.

1.2 Objetivos Específicos

- Desenvolver um algoritmo para extrair imagens de vídeos de forma automatizada.
- Utilizar lógica de programação para remover a presença do animal do contexto das imagens.
- Realizar a detecção e desenho de contornos em objetos com diferentes tamanhos, cores e formas, em diversas condições ambientais.
- Gerar a partir dos contornos um conjunto de métricas, em especial as coordenadas, dos objetos presentes na imagem.
- Validar o sistema comparando as coordenadas definidas pelo algoritmo com uma marcação manual efetuada através do software ImageJ.

2. REFERENCIAL TEÓRICO

Numerosos progressos concebidos na era moderna derivam da inata necessidade humana de atingir resultados específicos que nossa própria constituição não permite alcançar. Seja mediante a detecção de sinais em frequências elevadas, a observação de entidades microscópicas, a realização de operações complexas ou a métrica meticulosa de eventos que transcorrem em frações de segundos. Todos esses empreendimentos são conduzidos com alto grau de precisão e rigor metódico quando processados por ferramentas computacionais.

A seguir, serão expostos conceitos pertinentes ao Estudo do Comportamento, Experimentos de Memória, Tarefa de Reconhecimento de Objetos e Processamento Digital de Imagens, acompanhados de uma abordagem referente a pesquisas que empregam métodos computacionais para solucionar questões semelhantes ao objetivo proposto por esse projeto.

2.1. Conceitos Fundamentais

2.1.1. Estudos Comportamentais

O estudo comportamental é um campo promissor para profissionais de várias áreas acadêmicas. Compreender a estrutura e as causas dos comportamentos representa um desafio complexo para fundamentar argumentos sólidos na comunidade científica. É importante destacar que um mesmo comportamento pode ser decomposto em sequências de pequenas ações, influenciadas por diferentes estímulos que, por sua vez, estão condicionados à familiaridade do animal com o ambiente (Gris, Coutu & Gris, 2017).

Além disso, abordagens desse tipo exigem um número significativo de amostras e, quando manuais, podem ser enviesadas devido ao tempo de reação ou fadiga do observador pelas horas de atenção empregadas ao experimento, gerando problemas subsequentes para reprodutibilidade dos experimentos (Egnor e Branson, 2016). Atualmente, as ferramentas computacionais desempenham um papel fundamental na redução dessa complexidade (Anderson e Perona, 2014). A automação de certas atividades por meio dessas ferramentas permite um aumento na precisão e na quantidade de repetições nos testes comportamentais (Egnor e Branson, 2016). Dessa forma, contribuem para a obtenção de resultados mais confiáveis e robustos.

Os dados coletados desempenham um papel fundamental na geração de novas tecnologias e métodos na área do estudo comportamental. Métodos como o Processamento de Imagens e aplicações de redes neurais de múltiplas camadas fornecem novos horizontes no desenvolvimento de tecnologias inovadoras e aprimoramento dos métodos de análise. Portanto, a análise de dados das mais variadas fontes e processos torna-se uma etapa crucial no avanço contínuo dessa disciplina e no impulso de novas descobertas.

2.1.2. Memória de Objetos e Experimentos

A investigação dos mecanismos subjacentes à memória de reconhecimento de objetos por meio de experimentos comportamentais em animais envolve, segundo Ennaceur e Delacour (1988) o estudo de exploração espontânea. Essa linha de pesquisa visa compreender como os animais tomam decisões e processam informações sensoriais para formar memórias de objetos. A análise detalhada desses comportamentos pode

fornecer informações valiosas sobre como o cérebro humano entende e organiza as informações do ambiente ao seu redor (Bunsey e Eichenbaum, 1996).

Como uma característica intrínseca aos animais, a memória não é algo acessível para ser quantificada diretamente. Na origem dos estudos os fatores “lembranças e esquecimentos” eram fatos categóricos que geraram uma certa subjetividade de como os resultados eram interpretados pela academia.

O avanço da tecnologia é um dos pontos de virada para estudos assim, a aplicação de modelos matemáticos assegura o entendimento quantitativo dos padrões de comportamento, diminuindo a subjetividade e fazendo com que agora o foco seja na forma como é realizado o experimento (Anderson e Perona, 2014). Sendo aplicado a animais, quanto menor for a variação ambiental, os sentidos utilizados e as motivações melhor será para a interpretação da ação como um fruto da memória aplicada à atividade.

Ferramentas automáticas como uma câmera digital, sensores de movimento e microfones possibilitam essa imparcialidade na coleta e diminuem as variáveis que poderiam ser geradas ao animal ter contato físico ou sensorial com o humano durante o experimento. Junto a isso um processo de validação, novamente sem a interferência humana, excluiria o viés do pesquisador pelos resultados e aumentaria a eficiência da pesquisa.

2.1.3. Tarefa para Reconhecimento de Novos Objetos (NOR)

A memória de reconhecimento de objetos (ORM) desempenha um papel crucial na capacidade dos animais de distinguir entre elementos conhecidos e novos, fornecendo uma base para a tomada de decisões e o

processamento cognitivo (Gonzalez et al., 2019). Essa forma de memória permite que os organismos identifiquem e diferenciem objetos familiares em seu ambiente, fornecendo oportunidades em termos de sobrevivência e interação com o mundo ao seu redor.

A Tarefa de Reconhecimento de Novos Objetos é uma das formas de avaliar como essa memória é desenvolvida e quanto tempo ela consegue ser armazenada no sistema do animal a partir da intensidade e duração dos estímulos. Pesquisas como a de Gonzalez et al. (2019) utilizam dessa metodologia para estudar os mecanismos moleculares envolvidos na formação e atualização de memórias de longa duração.

2.1.4. Processamento Digital de Imagem

O Processamento Digital de Imagens (PDI) é um campo de pesquisa focado no uso de tecnologia embasado em conceitos de álgebra linear, geometria e cálculo, possuindo dois objetivos principais. O primeiro sendo o aprimoramento de informações extraídas visualmente. Já o segundo na análise automática de um cenário e a extração, transmissão e armazenamento de dados através do processamento de uma imagem.

De acordo com Marques Filho e Vieira Neto (1999) essa tecnologia encontra sua inspiração na observação da natureza física da óptica e na anatomia dos seres vivos, mais especificamente na forma como os seres vivos percebem a realidade por meio da absorção de fótons pelo sistema visual.

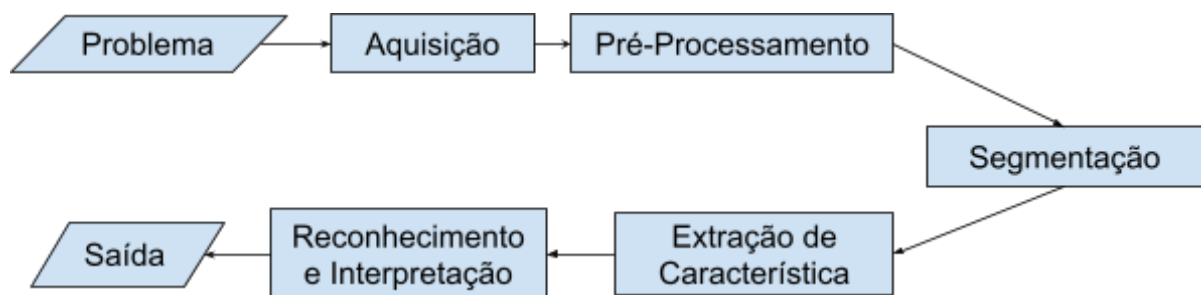
Assim como ocorre em diversas fontes de dados e informações, a análise de dados visuais também se baseia em conceitos bem definidos e passa por etapas fundamentais para o processamento e a obtenção de

resultados confiáveis. A partir da definição de uma imagem, que segundo Gonzalez e Woods (2010) é:

Uma função bidimensional, $f(x, y)$, onde “x” e “y” representam as coordenadas espaciais em um plano. A amplitude dessa função em cada par de coordenadas (x, y) é chamada de intensidade ou nível de cinza da imagem naquele ponto específico. Quando tanto coordenadas quanto os valores de intensidade são quantidades finitas e discretas, denominamos de imagem digital. (Gonzalez e Woods, 2010, pág. 1)

Na figura 1 é possível visualizar como é construído um pipeline usado de base para esquematização desse tipo de projeto:

Figura 1 – Sequência de Processamento



Fonte: Elaborado pelo autor (2023)

Conforme os trabalhos de Gonzalez e Woods (2010) e Marques Filho e Vieira Neto (1999) cada etapa é expressa da seguinte forma:

- Aquisição — É considerada como a etapa crucial, conseguindo simplificar ou deixar mais complexo todo o processamento,

envolve a conversão do sinal óptico em formato digital por meio de sensores e digitalizadores. Os sensores captam as ondas eletromagnéticas emitidas pelos objetos, enquanto os digitalizadores transformam a saída do sensor em dados digitais. Por isso a importância de avaliar as características do ambiente e dos objetos em que se cogita aplicar o algoritmo.

- **Pré-Processamento** — Etapa essencial visando realçar características de interesse. A imagem resultante do passo anterior pode conter imperfeições, como ruído, contraste inadequado e regiões conectadas. O objetivo do pré-processamento é melhorar a qualidade da imagem, utilizando operações de baixo nível que trabalham diretamente com os valores de intensidade dos pixels, as menores porções de uma imagem. Resultando em uma imagem digitalizada de melhor qualidade do que a original.
- **Segmentação** — Separar a imagem em regiões e objetos de interesse para permitir análises independentes de cada entidade. Essa tarefa é descrita de forma simples, mas é desafiadora de implementar. No contexto do problema, a segmentação pode ser dividida em duas etapas: primeiro, localizar os objetos entre os demais componentes da imagem, em seguida, segmentar cada instância individualmente.
- **Representação e Descrição** — consiste na extração de características das imagens segmentadas. Essas características são obtidas por meio de descritores que permitem caracterizar com precisão cada região. Os descritores são representados por uma estrutura de dados adequada ao algoritmo de

reconhecimento. Nessa etapa, a entrada ainda é uma imagem, porém a saída é um conjunto de dados correspondentes a essa imagem. Um exemplo de descritor poderia ser um vetor de três elementos contendo as coordenadas normalizadas x e y do centro de gravidade e a razão entre altura e largura da região.

- Reconhecimento e Interpretação — Atribuir um rótulo a um objeto com base em seus descritores. Na etapa de interpretação, busca-se atribuir significado a um conjunto de objetos reconhecidos.

2.2. Trabalhos Relacionados

2.2.1. Métodos de Aprendizagem de Máquina Aplicados a Análise de Imagens

Se tornou uma tendência nos últimos anos a aplicação de métodos supervisionados e não supervisionados na resolução de problemas envolvendo análise de imagens. Trabalhos como o de Gris, Coutu e Gris de 2017 que revisam os últimos estudos no comportamento de animais demonstram como a aplicação dessas técnicas deixou de ser algo esporádico e se tornou uma das melhores formas de otimizar experimentos e reduzir as taxas de erro.

Contudo, a aplicação dessa ferramenta requer ainda o uso de recursos computacionais durante o seu uso e desenvolvimento (), mesmo em trabalhos como o de Almeida et al. (2022) que conseguiu desenvolver uma biblioteca baseada no comportamento de animais a partir de técnicas não supervisionadas de aprendizagem de máquina a permitindo funcionar sem a utilização de recursos, é descrito que para seu treinamento foi utilizado 5

vídeos de cada cenário, resultando em 200 frames para marcação seguido por um protocolo de 320.000 iterações de treinamento.

Aplicações automáticas baseadas em técnicas tradicionais de processamento de imagens envolvem operações matemáticas clássicas, como filtros, limiarização, detecção de bordas, entre outros (Gonzalez e Woods, 2010). Adicionando o fato que diferente dos projetos anteriores ela não necessita de um banco de imagens para treino, consequentemente não leva horas rotulando amostras e processando, em um cenário controlado de luminosidade e ruídos como no caso desse projeto, ela pode alcançar resultados de precisão similares ao projeto de Almeida et al. (2022).

2.2.2. Uso de Redes Neurais na Segmentação de Objeto

A revisão bibliográfica realizada por Hesamian et al. (2019) apresenta uma análise abrangente das vantagens e desvantagens das técnicas de redes neurais aplicadas na área da medicina. Essa tecnologia foi desenvolvida para lidar com problemas complexos que envolvem padrões imperceptíveis aos olhos humanos, exigindo um processamento flexível para lidar com variações. Quando devidamente treinadas, essas ferramentas se adaptam a diferentes situações e reduzem a necessidade de intervenção humana no processo de segmentação de áreas de interesse em imagens.

No entanto, assim como nos modelos de aprendizado de máquina, todas essas funcionalidades demandam considerável poder computacional, uma quantidade significativa de dados rotulados e, consequentemente, tempo de processamento. É importante ter em mente esses requisitos ao optar por utilizar técnicas de redes neurais na segmentação de objetos.

Além disso, é comum aplicar técnicas de Processamento Digital de Imagens (PDI), como filtragem, equalização e limiarização, antes da etapa

de segmentação utilizando redes neurais. Isso possibilita obter resultados mais precisos e confiáveis na detecção e classificação de objetos em imagens, aproveitando o potencial de ambas as abordagens e promovendo avanços em diversas aplicações, como reconhecimento de padrões, diagnóstico médico e visão computacional.

Considerar a revisão bibliográfica de Hesamian et al. (2019) que destaca as vantagens e desvantagens das redes neurais aplicadas à medicina, reconhece o potencial dessas técnicas para lidar com padrões complexos e imperceptíveis aos olhos humanos, permitindo uma segmentação flexível e adaptável. Entretanto, é importante ressaltar que a atual fase do contexto de pesquisa carece de um banco de dados consolidado para aplicar diretamente redes neurais artificiais no entendimento dos dados produzidos pelo sistema.

3. METODOLOGIA

3.1. Ferramentas - Tarefa de Reconhecimento de Novos Objetos:

3.1.1. Objetos

Os objetos que serão utilizados nos testes de memória sendo os alvos de identificação desse sistema, ilustrados pela Figura 2, são compostos por vidro, plástico ou metal, de diferentes formas, cilíndricos, cúbicos entre outros, e cores podendo ser postos em pares, iguais ou distintos, porém idealmente não tendo predileção dos ratos (Rossato et al., 2019). A atribuição de papéis, identidades e posições relativas dos estímulos foi contrabalanceada em relação à área da arena.

Figura 2 – Itens do Experimento



Fonte: autor (2023)


3.1.2. Ambientação

O ambiente utilizado no experimento é retratado na Figura 3, caracterizado como uma caixa aberta de madeira, cujas dimensões são de 60cm x 60cm x 60cm (altura), possuindo uma tonalidade acinzentada como

cor de fundo. Esses parâmetros da caixa podem variar dependendo do autor do experimento, mas sempre mantendo essas mesmas proporções (Ennaceur e Delacour, 1988; Wally et al., 2022).

A junção da caixa, também conhecida como Arena, dos objetos e do animal é denominada como Contexto. Durante esse experimento foi possível utilizar simultaneamente até 4 contextos. Os mesmos posicionados em lugares diferentes da sala e consequente suscetíveis a diferentes intensidades de iluminação. Cabe destacar que, apesar das variações na iluminação, os contextos são idênticos em sua estrutura e configuração.

Figura 3 – Arena do Experimento



Fonte: Autor (2023)

3.1.3. Câmeras

No projeto, a captura das atividades dos objetos é realizada com precisão por meio de câmeras de vídeo digitais posicionadas estrategicamente a uma altura de 90cm acima das áreas de treinamento. Para esse fim, utilizamos uma câmera colorida Microsoft Lifecam Cinema,

com resolução de 1280 por 720, e uma câmera infravermelho Optitrack V100:R2, com resolução de 640 por 480. Os dados de vídeo são adquiridos de maneira padronizada, com taxa de 30 quadros por segundo para imagens coloridas e 50 quadros por segundo para imagens infravermelho. Importante ressaltar que as diferentes formas de gravação não afetam os resultados do algoritmo, tornando-o aplicável em qualquer uma dessas situações.

3.2. Ferramentas - Software

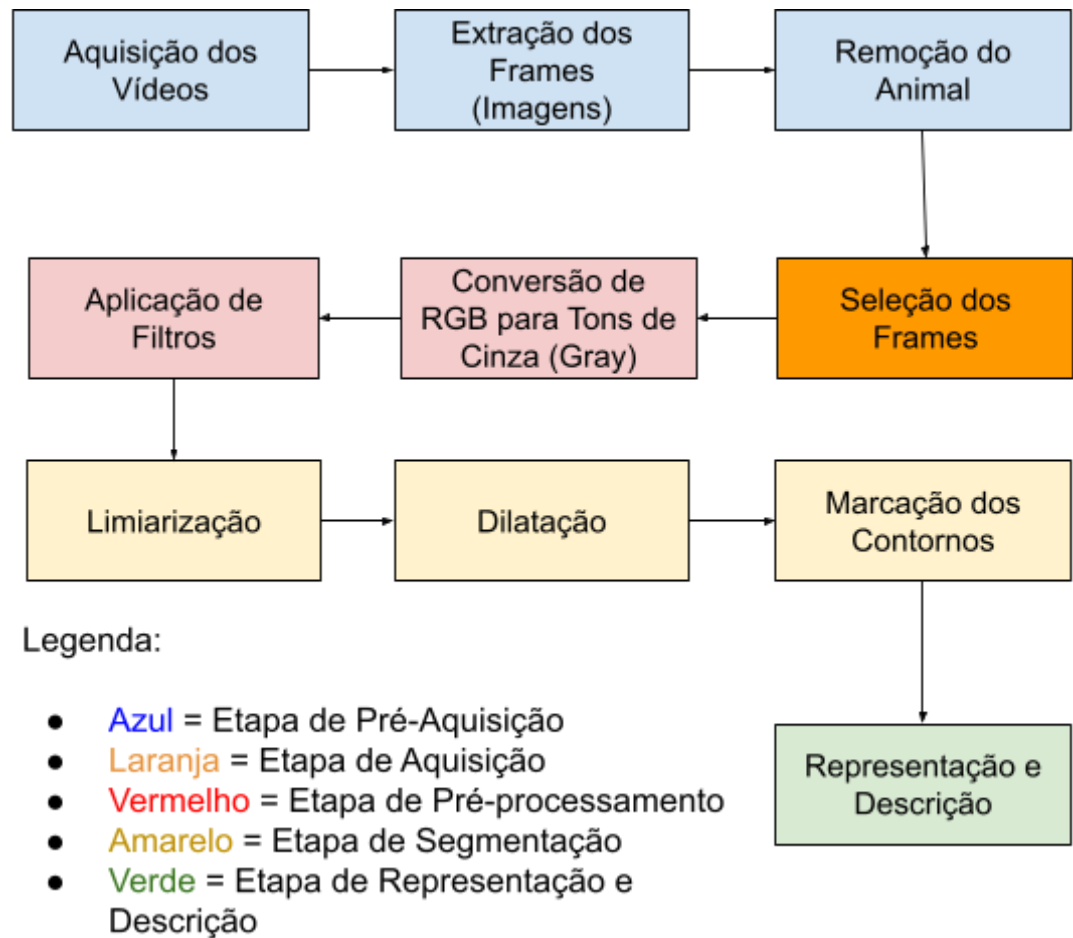
- Linguagem: Python (Versão: 3.10.12) - linguagem de programação poderosa e fácil de aprender. Possui estruturas de dados eficientes e abordagem simples para programação orientada a objetos. Python é amplamente utilizado para desenvolvimento web, ciência de dados, automação, IA e muito mais.
- Ambiente de Desenvolvimento: Google Colaboratory - Um ambiente de desenvolvimento integrado aos serviços de armazenamento do Google Drive, proporcionando acesso simplificado aos arquivos utilizados como entrada no sistema.
- Bibliotecas:
 - OpenCV (Versão: 4.7.0) - Biblioteca de Visão Computacional com várias funções para processamento de imagens e vídeos.
 - Numpy (Versão: 1.22.4) - Biblioteca fundamental para computação científica com suporte para arrays multidimensionais e funções matemáticas.

- Pandas (Versão: 1.5.3) - Biblioteca que oferece estruturas de dados e ferramentas para análise e manipulação de dados tabulares.
- Matplotlib (Versão: 3.7.1) - Biblioteca para criação de gráficos e visualizações de dados em Python.
- Seaborn (Versão: 0.12.2) - Biblioteca baseada no matplotlib para criação de gráficos estatísticos atraentes e informativos.
- Sistema de Validação: ImageJ (Versão: 1.54e) - Software de análise de imagens amplamente utilizado, oferecendo recursos avançados para processamento e medição de imagens.

3.3. Sistema

Seguindo o fluxo de um processamento de imagem, este sistema possui fases de desenvolvimento e algumas sub rotinas essenciais. Na figura 4 essas etapas são representadas pelas cores e as sub rotinas pela sequência de passos:

Figura 4 – Pipeline do Algoritmo



Fonte: Autor (2023)

3.3.1. Etapa: Pré-Aquisição das Imagens

A entrada inicial do sistema consiste em um link para uma pasta contendo os vídeos coletados durante os experimentos. Esses vídeos possuem duração variável e podem estar nos formatos colorido ou preto e branco (infravermelho). A partir desses vídeos, os frames são extraídos para serem processados pelo sistema. Conforme ilustrado na figura 5, esses frames são compostos por dois objetos, que podem ter formatos e tamanhos iguais ou diferentes, e também pelo animal, neste caso, um rato. É importante destacar que durante o vídeo animal pode estar posicionado em qualquer parte da arena, inclusive em cima dos objetos em questão.

Figura 5 – Componentes dos Experimentos



Fonte: autor (2023)

Considerando que o roedor não é relevante para a análise deste sistema, é necessário removê-lo da imagem da Arena. Para isso, foi desenvolvida uma função que utiliza a mediana dos pixels em diferentes imagens do mesmo vídeo. A mediana é uma medida estatística que representa o valor central de um conjunto de dados ordenados. Ao calcular a mediana para cada pixel em uma quantidade de imagens definida pelo usuário, a função identifica o valor menos afetado pelas mudanças causadas pelos corpos em movimento, mantendo o fundo estático constante e consequentemente as regiões de interesse para esse sistema, objetos.

A imagem resultante, obtida por meio da aplicação da mediana, atenua os pixels associados ao corpo em movimento, enquanto preserva o fundo estático. Essa abordagem possibilita que os objetos explorados pelo animal se destaquem de forma mais evidente, minimizando erros e simplificando a segmentação e análise posteriores (Figura 6).

Figura 6 – Imagem sem o animal



Fonte: autor (2023)

3.3.2. Etapa: Aquisição das Imagens

Após a remoção do animal as imagens são salvas em uma pasta no drive indicada pelo usuário, representando o processo de aquisição dessas imagens. O usuário antes de continuar com o sistema pode selecionar quais imagens são do seu interesse para o experimento ou eliminar possíveis imagens que não foram bem processadas, tornando o processo de criação do dataset algo personalizado para o seu experimento.


3.3.3. Etapa: Pré-Processamento

Após a seleção e dando progresso a compilação do sistema, a etapa seguinte visa realçar as regiões de interesse, uma vez que os objetos em questão possuem formatos geométricos distintos. Nesse sentido, utilizam-se filtros como o Laplaciano de Gaussiano e o operador de Sobel, que intensificam o contraste entre o corpo do objeto e o fundo da caixa (Figura 7b). Esse processo ressalta as bordas e detalhes dos objetos, tornando-os mais distintos e facilitando a identificação pelo sistema.

Figura 7 – Tons de Cinza e Aplicações de Filtros

(a) Tons de Cinza

(b) Resultado da Filtragem



Fonte: autor (2023)

3.3.4. Etapa: Segmentação

Na etapa de segmentação, foram aplicadas diversas técnicas utilizando a biblioteca OpenCV para identificar e isolar os objetos de interesse. O processo envolveu a utilização da técnica de limiarização com o método de Otsu, uma técnica de segmentação automática, capaz de definir um valor de limiar ótimo para distinguir o objeto do fundo (Figura 8a).

Para melhorar a definição das bordas e consolidar a segmentação, a imagem resultante passou por uma operação de dilatação, utilizando uma janela de pixels com área de 5x5. Esse processo de dilatação amplia as regiões de interesse, destacando ainda mais os objetos visualmente.

Finalmente, com a imagem adequadamente segmentada e as bordas dos objetos bem definidas, foram encontrados os contornos por meio do método "findContours" do OpenCV. Essa função permite identificar as bordas dos objetos e coletar as informações necessárias para a extração dos atributos relevantes para análise posterior (Figura 8b).


Essa sequência de processos permitiu não apenas uma segmentação adequada dos objetos de interesse, mas também a obtenção de informações valiosas sobre sua forma e posição na imagem.

Figura 8 – Contrastes e Contornos

(a) Limiarização e Dilatação



(b) Desenho dos Contornos



Fonte: Elaborado pelo autor (2023)

3.3.5. Etapa: Representação e Descrição

Após a marcação dos contornos utilizando a biblioteca OpenCV, foi possível extrair dados relevantes referentes aos atributos desses contornos. Neste trabalho, o foco foi na identificação precisa das coordenadas do centro dos objetos em questão. Essas informações foram coletadas e organizadas em um dataset, um conjunto estruturado de dados, onde cada linha representa um objeto identificado, e as colunas representam os atributos associados a esses objetos.

Ao final desta etapa, obteve-se um conjunto de dados estruturados, permitindo uma análise mais detalhada e sistematizada dos itens presentes nas imagens processadas. Esses dados são de grande importância para estudos posteriores, análises estatísticas e aplicação de algoritmos de

aprendizado de máquina, contribuindo para a realização de tarefas mais avançadas, como classificação automática e reconhecimento de padrões. Os resultados são apresentados na Tabela 1, que contém informações relevantes para cada objeto identificado, destacando-se os descritores *cx_momentun* e *cy_momentun*, que representam o centro do objeto resultante do algoritmo durante o processo de extração de características da imagem.

Tabela 1 – Atributo dos Objetos

attribute	área	cx_momentun	cy_momentun
Contexto3_obj1	5143.0	405	352
Contexto3_obj2	7261.5	263	352


Fonte: Elaborado pelo autor (2023)

3.3.6. Etapa: Reconhecimento e Interpretação dos Dados

A partir dos atributos extraídos das imagens, o pesquisador pode visualmente associar cada conjunto de características a um objeto específico (Figura 9). No entanto, a classificação automática desses objetos ainda não é suportada pelo sistema atual e é uma área a ser explorada em futuras versões do software. Essa melhoria possibilitará uma análise mais eficiente e precisa dos dados, proporcionando uma compreensão mais aprofundada do comportamento exploratório inato dos animais. Ao registrar o tempo que um animal dedica à exploração de um item específico, informações valiosas sobre suas preferências e interesses podem ser obtidas.

Com isso, o estudo contribuirá para o avanço da pesquisa em comportamento animal e áreas relacionadas, fornecendo uma base sólida para futuras investigações e análises comparativas.

Figura 9 – Futuras interpretações



Fonte: Elaborado pelo autor (2023)

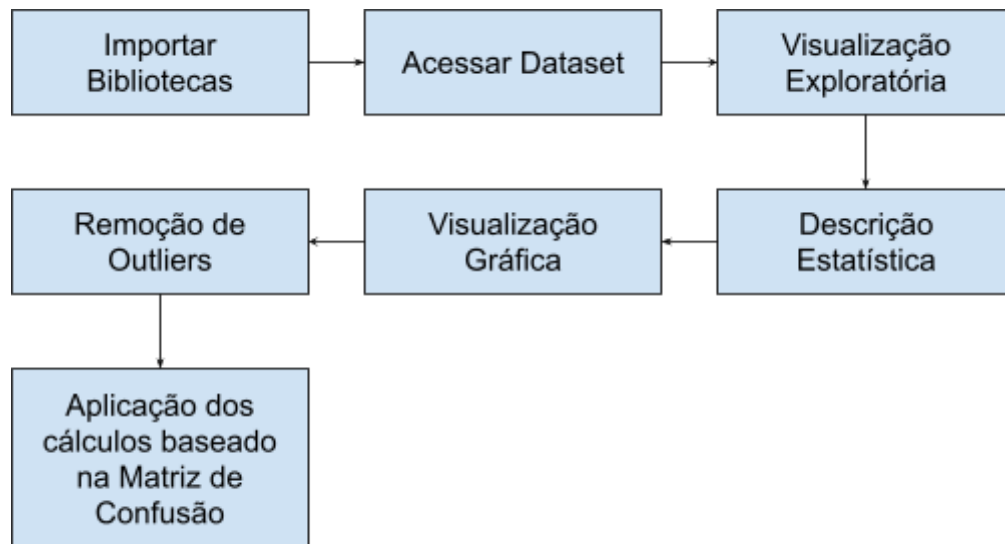
3.3.7. Etapa: Validação dos Resultados

A fim de validar o método proposto, foram realizadas duas vertentes de validação baseadas em 50 imagens, totalizando 100 amostras em diferentes cenários, formas de captura (colorida ou infravermelho), resoluções e categorias de objetos. A primeira vertente concentrou-se na detecção dos objetos presentes nas imagens, enquanto a segunda analisou a precisão das coordenadas dos centros dos objetos resultantes do algoritmo.

Para o processamento desses dados, foi desenvolvido um código dedicado exclusivamente à identificação de padrões dentro do conjunto de dados geral da pasta onde as imagens estavam armazenadas. Esse

processo foi realizado seguindo a sequência de passos ilustrados na Figura 10 através da utilização de bibliotecas como Pandas, Matplotlib e Seaborn.

Figura 10 – Fluxograma da Manipulação dos Dados



Fonte: Elaborado pelo autor (2023)

As métricas utilizadas ao final para o cálculo da matriz de confusão visando avaliar o desempenho do algoritmo na identificação de objetos incluem o Verdadeiro Positivo (TP), que representa as amostras corretamente identificadas como positivas; o Falso Positivo (FP), que são as amostras erroneamente identificadas como positivas; o Verdadeiro Negativo (TN), que são as amostras corretamente identificadas como negativas; e o Falso Negativo (FN), que são as amostras erroneamente identificadas como negativas.

Além disso, a validação do sistema foi realizada com base em métricas adicionais, como a Precisão (Figura 11), que mede a proporção de resultados corretos em relação aos resultados totais; a Taxa de Detecção ou Recall (Figura 12), que mede a capacidade do sistema em identificar corretamente as amostras positivas; e o F1-score (Figura 13), que combina a

precisão e a taxa de detecção para fornecer uma medida geral do desempenho do sistema.

Figura 11 - Cálculo de Precisão

$$\text{Precisão: } TP / (TP + FP)$$

Fonte: Elaborado pelo autor (2023)

Figura 12 - Cálculo de Recall ou Taxa de Detecção

$$\text{Recall (taxa de detecção): } TP / (TP + FN)$$

Fonte: Elaborado pelo autor (2023)

Figura 13 - Cálculo de F1-score

$$\text{F1-score: } 2 * (\text{precisão} * \text{recall}) / (\text{precisão} + \text{recall})$$

Fonte: Elaborado pelo autor (2023)

Para a validação das coordenadas foi usado o software ImageJ, uma reconhecida ferramenta de análise de imagens. Manualmente, os 100 objetos foram marcados utilizando a ferramenta de linha do ImageJ para encontrar o ponto central de cada objeto.

O método de comparação foi realizado ao aplicar o cálculo da distância euclidiana (Figura 10) entre os pontos marcados manualmente (x_1 , y_1) e pelo sistema (x_2 , y_2). Esse procedimento permitiu entender o comportamento das informações obtidas. Além da análise visual, foram

empregados métodos estatísticos, como a obtenção da média e do desvio padrão de todas as distâncias.

A Figura 10 ilustra o processo de cálculo da distância euclidiana entre os pontos, destacando a relevância dessa medida para análise de precisão da marcação dos centros dos objetos pelo sistema.

Figura 14 - Fórmula da distância euclidiana

$$\text{Distância Euclidiana} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Fonte: Elaborado pelo autor (2023)

4. RESULTADOS E DISCUSSÃO

Os resultados apresentados a seguir foram obtidos após a realização de diversos testes e aprimoramentos no sistema. Inicialmente, era perceptível um índice de erro significativo, com a ocorrência de falsos positivos ao identificar erroneamente o animal como um objeto. Essas limitações foram superadas por meio da implementação de uma função de "remoção do animal" e pela utilização de condicionais baseadas em métricas como área, raio, posição e circularidade dos objetos. Essas melhorias permitiram alcançar uma maior precisão na detecção dos objetos, resultando em resultados mais confiáveis e consistentes.

4.1. Discussão dos Resultados

Com base nos dados fornecidos, o sistema demonstrou um desempenho altamente preciso durante a análise das 50 imagens. De 100 objetos reais foram detectados 101 pelo sistema, apenas um erro de identificação foi registrado, caracterizando um falso positivo. Não houve omissão de objetos reais o que significaria um falso negativo, e como não há outra classe, não há registro de verdadeiro negativo. Indicando a robustez do sistema em identificar todas as ocorrências presentes nas imagens mas revelando um ponto que pode ser melhorado em projeto futuros, a captura de imagens sem objetos gerando testes para verdadeiros negativos.

A precisão do sistema alcançou cerca de 99.01% ao se basear no cálculo descrito pela matriz de confusão, refletindo um bom desempenho ao detectar corretamente os elementos em relação ao total de objetos reais. Além disso, o recall ou taxa de detecção atingiu um impressionante

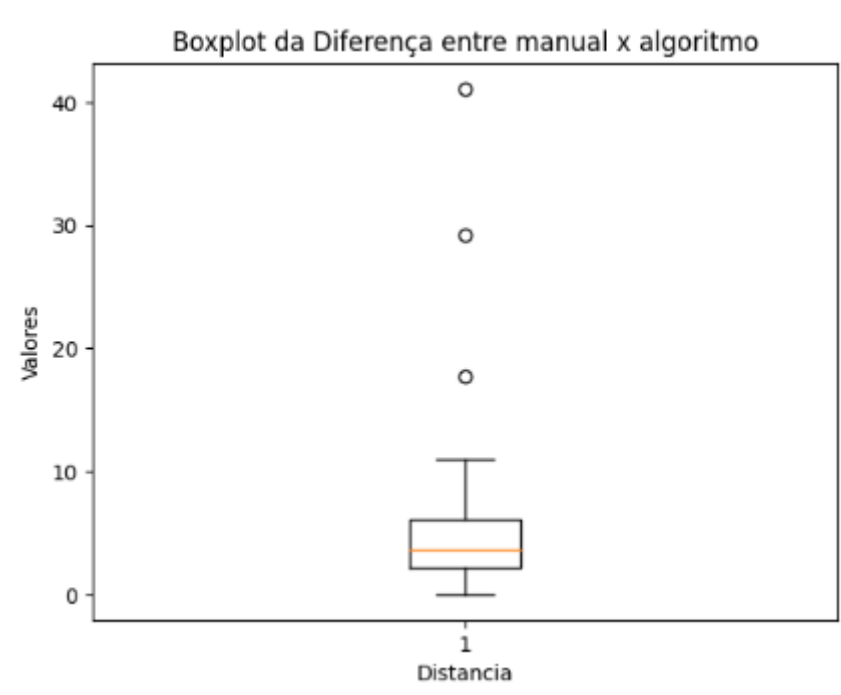
valor de 100%, evidenciando que todos os objetos verdadeiros foram corretamente identificados pelo sistema.

Outro aspecto importante é o F1-Score que também apresentou um valor elevado de cerca de 99.50%. Esse resultado reforça a consistência, eficácia e confiabilidade do sistema na tarefa de detecção de objetos, mostrando seu desempenho equilibrado em relação às métricas de avaliação e tornando-o uma valiosa ferramenta para pesquisas que requerem análise e identificação de objetos em imagens com modelos animais.

4.2. Precisão das Coordenadas

Após uma análise exploratória dos dados presentes no dataset contendo as coordenadas dos objetos, foi identificado que apenas 5 objetos apresentavam uma distância superior a 10 pixels entre o ponto central marcado no ImageJ e o ponto central feito pelo algoritmo (Figura 15).

Figura 15 - Gráfico Boxplot Manual X Algoritmo



Fonte: Elaborado pelo autor (2023)

Dos resultados observados, pode-se notar que os três últimos objetos exibiam uma distância acima de 17 pixels, o que teve um impacto considerável nas métricas de média e desvio padrão apresentadas na tabela de estatísticas descritivas (Figura 16). Uma característica comum entre esses três objetos foi identificada: todos eles pertenciam ao contexto 1 e, visualmente, suas bordas não se destacavam claramente em relação ao fundo da caixa. Essa particularidade levou o algoritmo a cometer erros significativos na identificação dos centros desses objetos, resultando nas distorções observadas nas métricas.

Tabela 2 – Parâmetros Iniciais Referentes à Distância

Atributos:	Distância Euclidiana entre os pontos
Mínimo	0
Máximo	41.01
Média	4.88
Desvio Padrão	5.14

Fonte: Elaborado pelo autor (2023)

No entanto, uma decisão importante foi tomada visando melhorar a precisão das coordenadas. Optou-se por remover temporariamente esses três objetos do conjunto de dados, a fim de avaliar o impacto na qualidade das métricas. Com essa exclusão, observou-se uma atenuação significativa nas métricas, revelando resultados mais aceitáveis e coerentes para a análise. Após a remoção dos três objetos, o algoritmo alcançou uma média de todas as distâncias de 4.07 pixels, com um desvio padrão de 2.66, conforme apresentado na Tabela 3.

Tabela 3 – Parâmetros Finais Referentes à Distância

Atributos:	Distância Euclidiana entre os pontos
Mínimo	0
Máximo	11.04
Média	4.07
Desvio Padrão	2.66

Fonte: Elaborado pelo autor (2023)

A utilização dessa abordagem possibilitou aprimorar os resultados e obter uma compreensão mais precisa do desempenho do algoritmo na detecção das coordenadas dos objetos. Com os valores corrigidos, o sistema demonstrou maior consistência na identificação precisa dos centros, o que é especialmente relevante considerando a importância da precisão das coordenadas em futuras aplicações. Essa melhoria no desempenho contribui para aumentar a confiabilidade e a utilidade do sistema para análises e aplicações futuras.

5. CONCLUSÃO

O projeto concluído representa uma solução inovadora para otimizar a identificação de elementos em experimentos de memória de reconhecimento de objetos. A ferramenta proposta demonstrou sua eficácia ao reduzir consideravelmente o tempo e o esforço necessários para encontrar a localização dos objetos utilizados durante o experimento. Possuindo resultados promissores e oferecendo uma base sólida para futuras aplicações nessa área de pesquisa em contínua expansão.

Para validar a precisão do método de identificação, foram conduzidos testes de desempenho, comparando os resultados gerados pelo sistema com as marcações manuais. Embora seja visto a necessidade de aprimoramentos adicionais para garantir uma robustez ainda maior, é importante destacar a consistência significativa observada nos resultados obtidos.

No contexto de estudos comportamentais e cognitivos, a implementação desse sistema pode ter um impacto notável, proporcionando uma análise mais ágil e precisa das atividades de reconhecimento de objetos em modelos animais. Ao eliminar as limitações da análise manual, os pesquisadores podem concentrar seus esforços em outras etapas cruciais da investigação, promovendo avanços significativos nesta área fascinante da ciência.

5.1. Contribuições

- Automação da Captura de Coordenadas: A tarefa de captura de coordenadas deixou de ser realizada manualmente e agora é realizada de forma automática, aumentando significativamente a velocidade das análises dos experimentos.
- Interface Amigável para Usuários Não Programadores: O sistema foi projetado para que os usuários não precisem ter um conhecimento profundo de programação. Apenas inserindo links para a pasta do Google Drive que contém os vídeos, a pasta de destino (que pode ser a mesma da entrada), a posição do nome do experimento e a quantidade de quadros desejada para a remoção do animal, o sistema poderá ser operado com facilidade.
- Disponibilidade de Banco de Imagens: O banco de imagens gerado por este projeto é salvo no drive do usuário, possibilitando futuras aplicações de algoritmos de machine learning ou redes neurais com propósitos mais específicos, como a classificação e reconhecimento desses objetos.
- Potencial para Aplicações Avançadas: As métricas, presentes nos datasets, podem ser aplicadas em conjunto com outros sistemas em tarefas mais avançadas, como a contagem das explorações do animal no objeto ou até mesmo a classificação de seus comportamentos em relação aos itens expostos.

5.2. Trabalhos Futuros

- **Impacto do Imobilismo Animal no Algoritmo de Remoção:** Quando o animal permanece imóvel em uma determinada região do vídeo por um período compatível com a fração de tempo utilizada pelo algoritmo de remoção, falhas podem ocorrer, resultando na interpretação incorreta dos resquícios do roedor ou na identificação equivocada de sua presença como um objeto do contexto.
- **Sensibilidade a Variações de Claridade:** Pequenas variações de iluminação podem afetar a correta identificação de elementos feitos de acrílico e metal não opacos, resultando em métricas fora do padrão quando tais elementos são identificados.
- **Identificação Incorreta de Objetos Externos ao Contexto:** Imagens que capturam elementos externos ao contexto do experimento podem levar a uma identificação incorreta ou indesejada de objetos.
- **Integração de Algoritmos de Aprendizagem de Máquina:** O algoritmo atual não realiza classificação ou representação dos objetos. Portanto, é viável explorar a aplicação de algoritmos de aprendizagem de máquina em uma fase posterior à segmentação.
- **Aprimoramento da Base de Dados:** A base de dados atual não contemplou vídeos em que não há presença de objetos ou que contenham mais de dois objetos no contexto. A inclusão desses casos é uma direção a ser aprimorada neste trabalho, a fim de melhorar ainda mais a confiabilidade e as métricas de precisão estabelecidas pela matriz de confusão.

REFERÊNCIAS


- ALMEIDA, T. F. et al. PyRAT: An Open-Source Python Library for Animal Behavior Analysis. **Frontiers in Neuroscience**, v. 16, article 779106, 2022. DOI: 10.3389/fnins.2022.779106. Acesso em: 14 jun. 2023
- ANDERSON, D. J.; PERONA, P. Toward a Science of Computational Ethology. **Neuron**, v. 84, n. 1, p. 18-31, 2014. DOI: 10.1016/j.neuron.2014.09.005.
- BEAR, M. F. et al. **Neurociências: desvendando o sistema nervoso** [recurso eletrônico]. 4. ed. Porto Alegre: Artmed, p. 823-852, 2017. p. 866-882. ISBN 978-85-8271-433-1.
- BUNSEY, M.; EICHENBAUM, H. Conservation of hippocampal memory function in rats and humans. **Nature**, v. 379, p. 255-257, 1996. DOI: 10.1038/379255a0. Acesso em: 21 jun. 2023
- EGNOR, S. E.; BRANSON, K. Computational analysis of behavior. **Annual Review of Neuroscience**, v. 39, p. 217-236, 2016. DOI: 10.1146/annurev-neuro-070815-013845. Acesso em: 24 jun. 2023
- ENNACEUR, A.; DELACOUR, J. A new one-trial test for neurobiological studies of memory in rats. 1: Behavioral data. **Behav Brain Res**, v. 31, n. 1, p. 47-59, nov. 1988. DOI: 10.1016/0166-4328(88)90157-x. PMID: 3228475. Acesso em: 20 jun. 2023
- GANDHI, Sumeet; MOSLEH, Wassim; SHEN, Joshua; CHOW, Chi-Ming. Automation, machine learning, and artificial intelligence in echocardiography: A brave new world. *Echocardiography*, [S.l.], 2018. doi: 10.1111/echo.14086.
- GÉRON, Aurélien; CONTATORI, Rafael (Trad.). **Mãos à Obra Aprendizado de Máquina com Scikit-Learn & TensorFlow: Conceitos, Ferramentas e Técnicas Para a Construção de Sistemas Inteligentes**. Rio de Janeiro: Alta Books, 2019, p. 1-18. ISBN: 978-85-508-0902-1.





- GONZALEZ, M. C. et al. Recognition memory reconsolidation requires hippocampal Zif268. **Sci Rep**, v. 9, p. 16620, 2019. DOI: 10.1038/s41598-019-53005-8. Acesso em: 14 jun. 2023.
- GONZALEZ, R. C.; WOODS, R. C. **Processamento digital de imagens. 3. ed.** São Paulo: Pearson Prentice Hall, 2010. p. 1-18. ISBN 978-85-8143-586-2. (Título original: Digital image processing)
- GRIS, K. V., COUTU, J.-P., & GRIS, D. Supervised and Unsupervised Learning Technology in the Study of Rodent Behavior. **Frontiers in Behavioral Neuroscience**, v. 11, 2017. DOI: <https://doi.org/10.3389/fnbeh.2017.00141>. Acesso em: 24 jun. 2023
- LAURINDO, G. M. et al. Thermal Environment and Behavior Analysis of Confined Cows in a Compost Barn. **Animals (Basel)**, v. 12, n. 17, p. 2214, 2022. DOI: 10.3390/ani12172214. Acesso em: 12 jul. 2023
- KANDEL, Eric R. et al. **Princípios De Neurociências.** 5ª edição. Porto Alegre: Mcgraw-Hill, 2014. 1256-1268 p. ISBN 9788580554052.
- Hesamian, M. H., Jia, W., He, X., & et al. Deep Learning Techniques for Medical Image Segmentation: Achievements and Challenges. **Journal of Digital Imaging**, v. 32, p. 582-596, 2019. DOI: <https://doi.org/10.1007/s10278-019-00227-x>. Acesso em: 25 jun. 2023
- MARQUES FILHO, O.; VIEIRA NETO, H. **Processamento Digital de Imagens.** Rio de Janeiro: Brasport, 1999. p. 3-10. ISBN 8574520098.
- ROSSATO, J. I. et al. PKM ζ Inhibition Disrupts Reconsolidation and Erases Object Recognition Memory. **J Neurosci**, v. 39, n. 10, p. 1828-1841, mar. 2019. DOI: 10.1523/JNEUROSCI.2270-18.2018. PMID: 30622166; PMCID: PMC6407297. Acesso em: 22 jun. 2023
- VALE, A. M. P. G. Técnica para segmentação automática de imagens microscópicas de componentes sanguíneos e classificação diferencial de leucócitos baseada em lógica fuzzy. Natal, RN, 2014.
- WALLY, M. E. et al. A short-term memory trace persists for days in the mouse hippocampus. **Commun Biol**, v. 5, p. 1168, 2022. DOI: 10.1038/s42003-022-04167-1. Acesso em: 14 jun. 2023.



APÊNDICE A - BASE DE IMAGENS E RESULTADOS

Segue algumas imagens de diferentes ambientes com diferentes objetos e os respectivos resultados.


1. Imagens Coloridas








2. Imagens em Escala de Cinza (Infravermelho)





3. Imagens com Deficiências no Processamento

