

Sistemas Inteligentes para Detecção e Classificação de Anemia Clínica causada por *Haemonchus contortus* em pequenos ruminantes

Anderson Thyago de Jesus Carvalho Baptista¹, Ricardo de Andrade Lira Rabelo¹

¹Departamento de Computação – Universidade Federal do Piauí (UFPI)
Teresina – PI – Brasil

{atjcb, ricardoalr}@ufpi.edu.br

Abstract. *In goat farming, parasitic diseases are a cause of losses. To avoid these diseases, anthelmintics drugs that help fight these parasites are used but the uncontrolled usage of those drugs can result in the appearance of super resistant helminths. In order to reduce the exaggerated usage of those substances, methods such as FAMACHA can be used to diagnose anemia and conduct a specific treatment. With that in mind, the purpose of this work is to detect and classify the FAMACHA Score of the animal. The proposed approach consists of the integration of Computer Vision and Intelligent Systems techniques in such a way to allow automatic detection and classification of the score. It is expected that the proposed approach can classify with good accuracy the FAMACHA Score of the animal.*

Resumo. *Na caprinocultura doenças parasitárias são causas de prejuízos. Para evitar essas doenças, são utilizadas drogas contra parasitos, porém, o uso descontrolado dessas drogas pode acarretar no surgimento de parasitos super resistentes. A fim de diminuir o uso exagerado dessas drogas, métodos como o FAMACHA podem ser utilizados para diagnosticar anemia e realizar um tratamento específico. Com isso em vista, o objetivo deste trabalho consiste em detectar e classificar o grau FAMACHA do animal. A abordagem proposta consiste na integração de técnicas de Visão Computacional e Sistemas Inteligentes de modo a permitir a detecção e classificação do grau. Espera-se que a abordagem proposta consiga classificar corretamente o grau FAMACHA do animal.*

1. Introdução

A produção e pesquisas com caprinos têm crescido consideravelmente em todo o mundo. Os reduzidos índices de produtividade nos rebanhos são frequentemente associados às infecções por parasitos no Brasil, principalmente por *Haemonchus contortus*, parasito que causa anemia nos animais contaminados, podendo levar à morte se não tratado [Molento et al. 2014]. Diversos criadores de caprinos no Brasil realizam tratamento intensivo contra parasitos em seu rebanho, chegando a utilizar medicamentos anti parasitos a cada 30 ou 60 dias, e isso é uma situação preocupante pois, mesmo que a maior parte dos parasitos sejam eliminados, poderá ocorrer pressão seletiva e parasitos resistentes irão sobreviver aos medicamentos [Molento et al. 2014].

A resistência aos medicamentos pelo *H. contortus* foi destacada como problema na exploração de pequenos ruminantes em diferentes regiões do mundo [Molento et al. 2014]. O diagnóstico da infecção pelo parasito normalmente é feito por meio do exame de fezes, onde ovos com menos de 85 µm e com aspecto multicelular podem ser

observados. Além do exame de fezes, métodos como o FAMACHA[®] e o escore de condição corporal podem ser usados para diagnóstico do animal, o que permite esse tratamento específico para o parasito.

O método FAMACHA[®] acabou sendo importante pois permitiu que o fazendeiro consiga determinar o grau FAMACHA[®] do animal para o diagnóstico da anemia sem precisar de exames mais complexos como o exame de fezes ou o escore de condição corporal, e com o diagnóstico da anemia é possível então realizar um tratamento contra o parasito, ajudando na redução da pressão seletiva e a poluição causada pelos medicamentos

Tendo em vista a importância do método FAMACHA[®] para auxiliar na produção e pesquisa com ovinos, o objetivo desse trabalho é implementar uma solução computacional que faça uso de Visão Computacional e Sistemas Inteligentes para estimar corretamente o grau FAMACHA[®] de um caprino por meio de uma foto da conjuntiva do caprino.

Com essa solução computacional, é esperado que consigamos auxiliar os fazendeiros responsáveis pelos animais para realizar um tratamento adequado, pois poderemos classificar com mais facilidade o grau FAMACHA[®] do animal.

O trabalho está dividido nas seguintes seções: a seção 2 descreve o referencial teórico, isso é, a pesquisa e os estudos envolvidos que permitiu a criação deste trabalho, a seção 3 descreve os objetivos, a seção 4 descreve a metodologia, que explica as etapas do desenvolvimento deste trabalho, a seção 5 comenta sobre os resultados obtidos, a seção 6 cita a conclusão deste trabalho e por último a seção 7 mostra algumas considerações finais sobre o trabalho.

2. Referencial Teórico

2.1. Método FAMACHA

Após anos de pesquisa na África do Sul, estabeleceu-se correlação entre a coloração da conjuntiva ocular de pequenos ruminantes e cinco intervalos de anemia indicados pelo exame de sangue, que mede a porcentagem de células vermelhas e através dessa correlação, foi criado o método FAMACHA[®], onde é utilizado um cartão (cartão FAMACHA[®]) para verificar a coloração da conjuntiva ocular do caprino e determinar o grau FAMACHA[®] do animal, que pode variar entre 1 a 5, onde os graus 1 e 2 são de animais com a coloração bem vermelha, ou seja, sem traços visíveis de anemia, o grau 3 já possui um tom vermelho mais fraco, e nele é indicado o tratamento contra o verme e os graus 4 e 5 possuem um tom vermelho quase branco, indicando anemia severa, sendo necessário a vermifugação do animal, precisando até mesmo de suplemento alimentar se o grau for igual a 5 [Molento et al. 2007].



Figura 1. Imagem do cartão FAMACHA®, onde é mostrado os graus. Fonte: Carvalho, Camila & Molento, Marcelo. (2015). Embrapa Famacha Circular Técnica 52.

2.2. Aspecto Computacional

2.2.1. FAMACHA

O método FAMACHA® já teve uma boa eficácia no combate ao *H. contortus*, como é mostrado em [Molento et al. 2004, Molento et al. 2007, Van Wyk 2009], aplicações que utilizam esse método foram feitas para auxiliar agricultores. Em [Carvalho et al. 2016], um sistema de gerenciamento de rebanho de caprinos e ovinos chamado Capriovi foi desenvolvido para o melhoramento genético de caprinos e ovinos e em [Castro et al. 2018], um módulo para geração de um relatório de vermifugação foi gerado para o Capriovi, levando em conta os valores relacionados ao exame de fezes, o escore de condição corporal e o grau FAMACHA®. É então aplicado Sistemas *Fuzzy* (Lógica Difusa), para receber os valores e é retornado para o usuário uma nota de 0 a 10, indicando a saúde do animal, onde quanto menor a nota, mais o animal está parasitado e precisa de tratamento. Já em [Demoliner e Fernandes 2017] uma aplicação mobile para identificação do grau FAMACHA® de um animal foi desenvolvida utilizando o algoritmo baseado em aprendizado de máquina Naive Bayes

2.2.2. Visão Computacional e Sistemas Inteligentes

Com o rápido avanço tecnológico, aplicações envolvendo reconhecimento de imagem começaram a fazer parte do cotidiano, como sistemas de reconhecimento facial ou de

reconhecimento de impressões digitais nos nossos telefones celulares. Sistemas antigos utilizavam *Scale-Invariant Feature Transform* e *Histogram of Oriented Gradients* para realizar esse reconhecimento, porém eles atuavam somente em casos bem específicos, com baixa capacidade de generalização, sendo assim, era necessário um método mais genérico que pudesse obter melhores resultados em cenários diversos [Liu et al. 2017].

O avanço da inteligência artificial acarretou no surgimento das Redes Neurais Artificiais (ANN, do inglês Artificial Neural Networks), uma técnica computacional inspirada na estrutura e no funcionamento do sistema nervoso biológico, com a capacidade de “aprendizado”, que envolve o ajuste dos pesos sinápticos de cada um dos neurônios para atingir um objetivo específico. As ANNs utilizam uma série de neurônios artificiais, onde cada entrada do neurônio é ponderada por um peso sináptico, em seguida o resultado da soma ponderada das entradas e pesos é subtraído de um determinado limiar e então é aplicada uma função de ativação em cima do resultado, essa função que determina o sinal de saída daquele neurônio. A saída do neurônio então pode ser utilizada para alimentar outros neurônios de outras camadas ou até mesmo ser usada para realimentar o próprio neurônio, dependendo da arquitetura usada [Krogh 2008].

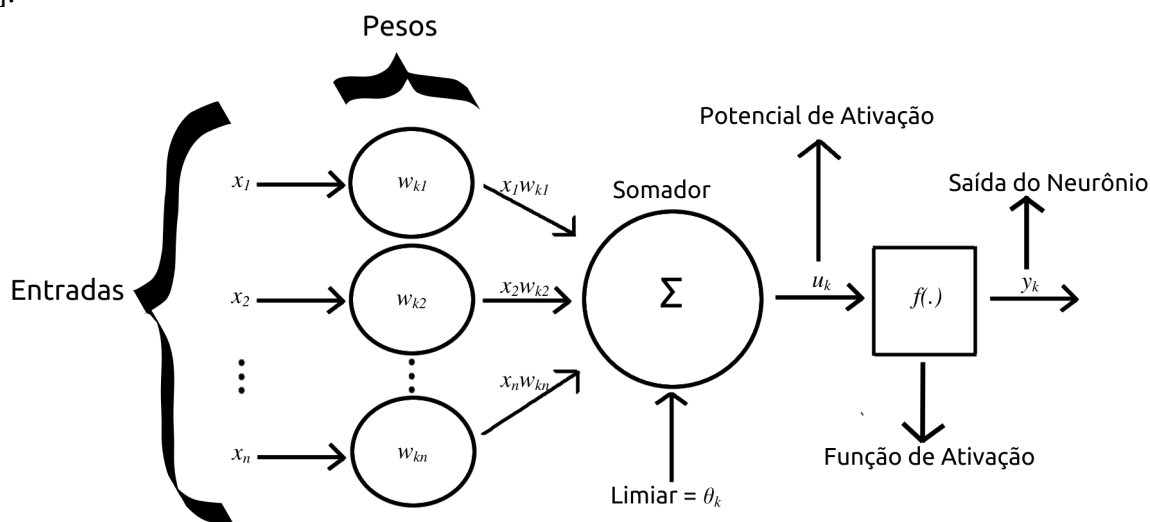


Figura 2. Um exemplo de Neurônio Artificial. Fonte: Elaboração própria

Nas ANNs, uma arquitetura simples e famosa é o Perceptron, onde o mesmo neurônio artificial era usado e tinha a capacidade de ser “treinado” utilizando dados de entrada e saída conhecidos [Rosenblatt 1958] e a partir desse Perceptron, surgiu uma arquitetura conhecida como Perceptron Multicamadas (MLP, do inglês Multi Layer Perceptron), que consiste em várias camadas com vários Perceptrons em cada camada. Essa arquitetura foi criada pois um único Perceptron não era capaz de resolver problemas complexos, como classificar a porta lógica XOR, e era restrito a somente problemas de classificação linear [Riedmiller e Lernen 2014]. Com essas capacidades adicionais do MLP, foi possível aplicar ele em problemas mais complexos, incluindo o de classificação de imagens

Além do Perceptron e das MLPs, uma arquitetura muito utilizada de ANNs é a Rede Neural Convolutiva (CNN, do inglês Convolutional Neural Network), que é

inspirado no córtex visual animal, projetado para imagens visuais, sendo utilizada em aplicações como reconhecimento de padrões, reconhecimento de voz, reconhecimento de linguagem natural, análise de vídeo e outros [Liu 2018]. Em 1989, um modelo da CNN proposto por [LeCun et al. 1989] conhecido como LeNet foi desenvolvido e testado com diferentes objetivos envolvendo reconhecimento de imagem, obtendo um bom resultado, se tornando um sistema de reconhecimento de imagens universal [Liu et al. 2017].

Desde então, as CNN vêm se tornando cada vez mais usadas em aplicações envolvendo reconhecimento de imagem, inclusive na área da saúde, com trabalhos mostrando a aplicação disso para detecção de pneumonia bacteriana ou viral [Yadav et al. 2019], detecção de melanomas [Efimenko et al. 2020], detecção de tumores cerebrais [Othman e Basri 2011], além de aplicações na área da agricultura, como detecção de doenças em plantas [Wang et al. 2012] ou reconhecimento facial de cabras para contagem e gerenciamento [Masum et al. 2022]. Abordagem mistas envolvendo CNNs e MLPs também já foram testadas para classificação de imagens, como a classificação de navios em imagens formadas por radares de abertura sintética [Sharifzadeh et al. 2018], detecção de câncer de mama [Desai e Shah 2021].

3. Objetivos

3.1. Objetivos Gerais

- Construir uma solução computacional que faça uso de Visão Computacional e Sistemas Inteligentes para auxiliar na identificação e classificação do grau FAMACHA[®] por meio de imagens em caprinos.

3.2. Objetivos Específicos

- Realizar estudos para avaliar se tecnologias parecidas já foram implementadas antes, para auxiliar no desenvolvimento
- Estudar como é a aplicação do método FAMACHA[®] e desenvolver uma arquitetura para simular o método, levando em conta uma imagem como entrada
- Implementar a solução computacional

4. Metodologia

4.1. Pesquisa e Estudos

Inicialmente, foi realizada uma leitura de artigos científicos, seminários e apresentações de como funciona o método FAMACHA[®]. Após a compreensão do método em questão, foi realizada uma pesquisa sobre métodos da área de Visão Computacional e Sistemas Inteligentes para encontrar um método que seja eficiente e também tenha um custo computacional baixo, para que a solução encontrada possa ser usada no futuro em aplicações mobile para a maior quantidade de fazendeiros possíveis.

4.2. Obtenção das Imagens

Um banco contendo 137 imagens foi disponibilizado pela empresa IAGRO e o ocular das 137 imagens foi recortado manualmente para ser utilizado na classificação, como é mostrado na Figura 3. Além das imagens, os valores do grau FAMACHA[®] de cada animal foi disponibilizado, distribuído nos seguintes graus de acordo com a Tabela 1.

Tabela 1. Quantidade de imagens por grau FAMACHA

| Grau | Quantidade |
|------|------------|
| 1 | 4 |
| 2 | 48 |
| 3 | 55 |
| 4 | 22 |
| 5 | 8 |




Figura 3. Exemplo de recorte ocular dos animais.

4.3. Pré-Processamento

Antes da classificação das imagens, foi realizado um pré-processamento para melhorar as imagens. Como é preciso somente da parte vermelha do olho, a parte mais escura da

foto, seja a pupila ou os próprios pêlos, podem interferir no resultado da classificação. Para isso, foi aplicado um filtro HSV para detecção de vermelho.

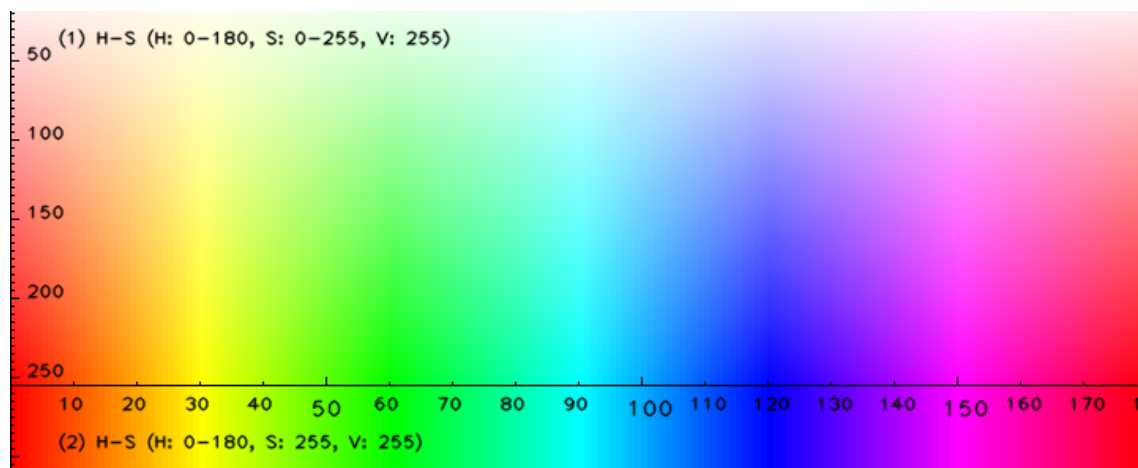


Figura 4. Mapa de Cor HSV. Fonte: Packt Subscription

No mapa de cor HSV, a faixa do vermelho possui um valor de matiz (*Hue*) entre 0 a 20 ou entre 160 a 180. O filtro então faz uma varredura na imagem, selecionando os pixels da imagem que possuem valor de matiz em alguma dessas duas faixas. Os pixels que não estão nessa faixa são modificados para terem valor HSV de (0, 0, 0), valor HSV correspondente a cor preta, esses pixels então podem ser facilmente ignorados durante a classificação. Na Figura 5 temos um exemplo da imagem após aplicação deste filtro.



Figura 5. Exemplo de recorte ocular dos animais após a aplicação do filtro HSV

4.5. Implementação

A implementação do sistema foi feita utilizando a linguagem *Python* em sua versão 3.8. Para a leitura e manipulação de imagens, a biblioteca *opencv* foi utilizada. Foi escolhido o Perceptron e o MLP para a implementação, e os classificadores foram implementados

utilizando a biblioteca *scikit-learn*. O treinamento e teste das ANNs selecionadas foram realizados automaticamente através dessa biblioteca *scikit-learn*. As CNNs foram consideradas mas descartadas devido a sua complexidade e seu custo computacional.

Para o Perceptron, foram utilizados os parâmetros padrões da biblioteca, já no MLP alteramos a quantidade de iterações para 3500 iterações.

4.6. Classificação

Após a obtenção das imagens e o pré-processamento, foi realizada a classificação. A classificação foi realizada de dois modos distintos: O primeiro modo foi utilizando os canais de cores RGB e o segundo modo foi utilizando os canais de cores HSV.

4.6.1. RGB

Inicialmente, cada imagem foi processada e foram calculados os valores médios de cada um dos canais de cor RGB da imagem (Vermelho, Verde e Azul), ignorando os pixels com valor RGB de (0, 0, 0), que são os pixels que o filtro modificou por não serem vermelhos.

Foi então feita uma lista de tuplas, onde o primeiro valor representa a lista dos valores médios, e o segundo valor representa o grau FAMACHA[®] obtido para cada imagem. Assim, foi possível realizar o treinamento supervisionado do Perceptron e do MLP.

4.6.1. HSV

Do mesmo modo que foi feito para o canal RGB, também foi realizado o cálculo dos valores médios de cada um dos canais de cor HSV da imagem (Matiz, Saturação e Valor), sendo utilizado na lista de tuplas do mesmo modo que o canal RGB.

4.7. Validação

Para validar os resultados, foi utilizado o valor do Score do Perceptron e do MLP. O Score é calculado utilizando a seguinte fórmula:

$$Score = \frac{Total\ de\ Acertos}{Total\ de\ Imagens}$$

Onde um acerto ocorre quando o grau previsto pelo Perceptron ou do MLP é igual ao grau da imagem, já conhecido previamente. O valor do Score é medido em porcentagem (%), com um valor entre 0 e 100, onde 100 é o melhor valor, ocorrendo quando a ANN consegue prever corretamente todas as imagens.

Para o MLP em específico, o cálculo do Score é feito utilizando uma média de 500 execuções distintas, pois os parâmetros aleatórios do MLP da biblioteca *scikit-learn* geraram resultados diferentes para cada execução.

5. Resultados

Os valores dos Scores são mostrados nas Tabelas 2 e 3.

Tabela 2. Scores utilizando o canal de cor RGB

| Método | Score(%) |
|------------|----------|
| Perceptron | 43.065 |
| MLP | 49.503 |

Tabela 3. Scores utilizando o canal de cor HSV

| Método | Score(%) |
|------------|----------|
| Perceptron | 44.525 |
| MLP | 66.627 |

O MLP teve resultados superiores tanto no RGB quanto no HSV, e o HSV mostrou ser bem melhor que o RGB, chegando a ser 15% melhor no MLP. No melhor dos casos o MLP chegou a atingir um Score(%) de 82.481, classificando corretamente boa parte das amostras, como visto no quadro 1, com a diagonal destacada mostrando os acertos.

Quadro 1. Matriz de confusão do MLP

| | | Grau Obtido | | | | |
|---------------|---|-------------|----|----|----|---|
| | | 1 | 2 | 3 | 4 | 5 |
| Grau Esperado | 1 | 2 | 0 | 2 | 0 | 0 |
| | 2 | 0 | 43 | 5 | 0 | 0 |
| | 3 | 0 | 9 | 45 | 1 | 0 |
| | 4 | 0 | 1 | 5 | 16 | 0 |
| | 5 | 0 | 0 | 0 | 1 | 7 |

De acordo com o quadro 1, observa-se que a classificação teve bons resultados, especialmente para o grau 2, 3 e 5, com uma taxa de acerto acima de 80% para os graus. Para o grau 1, a taxa de acerto foi de 50% enquanto que para o grau 4, a taxa foi de 72.7%.

Durante a execução do trabalho, alguns problemas foram encontrados. O primeiro problema foi a baixa quantidade de imagens do grau 1, 4 e 5. Por mais

que o MLP tenha uma taxa de acerto de 87.5% para o grau 5, ao todo só teve 8 imagens desse grau, então não é uma quantidade que dê para confiar que o MLP aprendeu exatamente como calcula esse grau. O mesmo pode ser dito para os graus 1 e 4, ambos possuindo uma quantidade baixa de imagens.

Além desse problema, também tivemos imagens onde o brilho da imagem interferiu na classificação, pois o grau da imagem na imagem parecia ser diferente do grau FAMACHA® conhecido do animal. Esse problema geralmente ocorre por conta do flash da câmera, ou por conta do sol refletindo no olho. A figura 6 mostra um exemplo desse erro, onde os dois recortes possuem o mesmo grau FAMACHA®, com valor 2, porém a imagem da direita, por ser um pouco mais clara, o MLP classificou ela como sendo de grau 3.



Figure 6. Exemplo do problema de brilho das imagens.

6. Conclusão

Após a realização de estudos sobre o método FAMACHA® e métodos de visão computacional e sistemas inteligentes para classificação de imagens, um conjunto de imagens foi disponibilizado pela empresa IAGRO para realizarmos o trabalho. Feito um recorte manual nas imagens e um pré-processamento para destacarmos os aspectos mais importantes da imagem, foram treinados 2 modelos de classificação: o Perceptron e MLP para realizar a classificação da imagem. Os valores médios dos canais de cores RGB e HSV foram utilizados como entrada para esses modelos, enquanto que a saída era o grau famacha da figura, também disponibilizado pela IAGRO. Esses dados de entrada e saída realizaram o treinamento dos modelos e permitiram também a testagem deles, sendo o MLP o modelo que exibiu os melhores resultados.

A solução implementada poderá ser de grande importância para a caprinocultura, pois permitirá simplificar a classificação do grau FAMACHA®, possibilitando a realização de um tratamento mais adequado para o animal. A implementação da solução em um aplicativo futuro deve ajudar o criador de animais a cuidar da saúde deles de maneira mais simples, sem precisar comprar o cartão FAMACHA® pela internet, entrega que poderá levar semanas dependendo do local.

7. Considerações Finais

Como trabalho futuro, será implementada uma aplicação que embarca esta solução para que seja utilizada por fazendeiros no dia a dia. Ela também contará com métodos de detecção automática do ocular para evitar o recorte manual feito pelo humano.

Além disso, será buscado maneiras de melhorar a qualidade da solução, como aumentar a quantidade de imagens utilizadas para o treinamento da rede, além de serem testadas novas alternativas, como utilizar como entrada os valores RGB e HSV ao mesmo tempo, ao invés de usarem os valores de maneira exclusiva e também estudar outros modelos de cores além do RGB e o HSV para ver se algum outro modelo pode ter uma eficácia melhor que o HSV.

8. Referências

- Albawi, S., Mohammed, T. A., Al-Zaw, S. i, "Understanding of a convolutional neural network," 2017 International Conference on Engineering and Technology (ICET), 2017, pp. 1-6, doi: 10.1109/ICEngTechnol.2017.8308186.
- Carvalho, T., Santos, N., Lira, W., Oliveira, P.A., Santos Neto, P., Lindenberg, J., Rabêlo, R., Um Sistema de Informação para Melhoramento Genético de Caprinos e Ovinos. In: SIMPÓSIO BRASILEIRO DE SISTEMAS DE INFORMAÇÃO (SBSI), 12. , 2016, Florianópolis. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2016 . p. 100-107.
- Castro, O., Borges, L., Pereira, A., Lima , F., Parentes, M., Sarmiento, L., & Santos , P. (2018). Módulo Computacional para Indicação de Tratamento Anti-helmíntico em Caprinos e Ovinos. In Anais da IV Escola Regional de Informática do Piauí, (pp. 274 - 279). Porto Alegre: SBC.
- Chagas, A. O., Márcia, Carvalho, C.O., Molento, M. (2007). Método FAMACHA©: Um recurso para o controle da verminose em ovinos. Circ. Téc.. 52. 1-8.
- Demoliner, G., Fernandes Alves, R. J. (2017). Anemímetro: app móvel para implementação do método Famacha. Unoesc & Ciência - ACET, 8(1), 25–32. Recuperado de <https://portalperiodicos.unoesc.edu.br/acet/article/view/12770>
- Depner, R., Gavião, A., Cecim, M., Rocha, R. & Molento, M. (2008). Desempenho de cordeiros naturalmente infectados com parasitas gastrintestinais utilizando o tratamento seletivo com o método famacha e o tratamento preventivo. Archives of Veterinary Science. 12. 10.5380/avs.v12i3.10920.
- Desai, M., Shah, M. An anatomization on breast cancer detection and diagnosis employing multi-layer perceptron neural network (MLP) and Convolutional neural network (CNN). Clinical eHealth, v. 4, p. 1-11, 2021
- Efimenko, M., Ignatev, A., Koshechkin, K. Review of medical image recognition technologies to detect melanomas using neural networks. BMC Bioinformatics 21, 270 (2020). <https://doi.org/10.1186/s12859-020-03615-1>
- Fernandes, Maria Angela M. et al. Método FAMACHA para detectar anemia clínica causada por *Haemonchus contortus* em cordeiros lactentes e ovelhas em lactação.

- Pesquisa Veterinária Brasileira [online]. 2015, v. 35, n. 06 [Acessado 20 Março 2022] , pp. 525-530. Disponível em: <<https://doi.org/10.1590/S0100-736X2015000600006>>. ISSN 1678-5150. <https://doi.org/10.1590/S0100-736X2015000600006>.
- Krogh, A. What are artificial neural networks?. *Nat Biotechnol* 26, 195–197 (2008). <https://doi.org/10.1038/nbt1386>
- Liu, Q., Zhang, N., Yang, W., Sile, W., & Cui, Z., & Chen, X., & Chen, K. (2017). A Review of Image Recognition with Deep Convolutional Neural Network. 69-80. 10.1007/978-3-319-63309-1_7.
- Liu, Y. (2018). Feature Extraction and Image Recognition with Convolutional Neural Networks. *Journal of Physics: Conference Series*. 1087. 062032. 10.1088/1742-6596/1087/6/062032.
- Masum B., , Xihong W., , Jiantao Y., Yu J., Real-time goat face recognition using convolutional neural network, *Computers and Electronics in Agriculture*, Volume 194, 2022, 106730, ISSN 0168-1699, doi:10.1016/j.compag.2022.106730.
- Molento, Marcelo Beltrão et al. Método Famacha como parâmetro clínico individual de infecção por *Haemonchus contortus* em pequenos ruminantes. *Ciência Rural* [online]. 2004, v. 34, n. 4 [Acessado 20 Março 2022] , pp. 1139-1145. Disponível em: <<https://doi.org/10.1590/S0103-84782004000400027>>. Epub 30 Ago 2004. ISSN 1678-4596. <https://doi.org/10.1590/S0103-84782004000400027>.
- Othman, M. F., Basri, M. A. M. "Probabilistic Neural Network for Brain Tumor Classification," 2011 Second International Conference on Intelligent Systems, Modelling and Simulation, 2011, pp. 136-138, doi: 10.1109/ISMS.2011.32.
- Riedmiller, M., Lernen, A. Multi layer perceptron. *Machine Learning Lab Special Lecture*, University of Freiburg, p. 7-24, 2014.
- Rosenblatt, F. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, v. 65, n. 6, p. 386, 1958.
- Sharifzadeh, F., Akbarizadeh, G. & Seifi Kavian, Y. Ship Classification in SAR Images Using a New Hybrid CNN–MLP Classifier. *J Indian Soc Remote Sens* 47, 551–562 (2019). <https://doi.org/10.1007/s12524-018-0891-y>
- Van Wyk, J. (2009). Production trials involving use of the FAMACHA© system for haemonchosis in sheep: Preliminary results. *The Onderstepoort journal of veterinary research*. 75. 331-45. 10.4102/ojvr.v75i4.109.
- Wang, H., Li, G., Ma, Z., & Li, X. (2012). Application of neural networks to image recognition of plant diseases. 2012 International Conference on Systems and Informatics, ICSAI 2012. 2159-2164. 10.1109/ICSAI.2012.6223479.
- Yadav, S., Jadhav, S. (2019). Deep convolutional neural network based medical image classification for disease diagnosis. *Journal of Big Data*. 6. 10.1186/s40537-019-0276-2.

Zhang, C., Pan, X., Li, H., Gardiner, A., Sargent, I., Hare, J., & Atkinson, P. M. (2018). A hybrid MLP-CNN classifier for very fine resolution remotely sensed image classification. *ISPRS Journal of Photogrammetry and Remote Sensing*, 140, 133-144.